

Taller 6: Regresión Lineal Simple en R

Métodos Cuantitativos II

M. Constanza Ayala

maria.ayala@uv.cl

[Agenda una reunión aquí](#)

Escuela de Sociología - Universidad de Valparaíso

22 de abril, 2026

Pasemos lista mientras descargan los materiales y dejamos todo listo ✨

 **Paso 1:** Abrimos nuestro proyecto con doble clic en el archivo `.Rproj`

- Si no tienen proyecto, creamos uno: `File > New Project > New Directory > New Project`
- Creamos carpetas: `data`, `scripts`, `figures`, `output`

 **Paso 2:** Movemos el archivo **Script Taller 6 Métodos Cuantitativos II.R** a la carpeta `scripts`

 **Paso 3:** Verificamos que la base **Base de datos Casen 2022.Rdata** esté en la carpeta `data`

Todos los materiales los pueden descargar en este link: [Materiales clases](#)

Evaluación 3

Hoy tenemos nuestra **tercera evaluación individual** en R. Debes entregar lo siguiente:

- Proyecto de R (.Rproj).
- El script (.R) que contiene todos los ejercicios individuales solicitados en este taller. Debes crear un script nuevo, no utilices el script de actividades entregado en la clase.
 - En ese script, incluye un título, tu nombre, correo y fecha. Por ejemplo:

```
1 # Script Ejercicio 3 Métodos Cuantitativos II -----  
2 # M. Constanza Ayala (maria.ayala@uv.cl)  
3 # 22-04-2026
```

Plazo de entrega: hoy hasta las 23:59 hrs. en el Aula Virtual.

En caso de utilizar IA, debe reportarlo en un archivo Word, indicando la herramienta y los prompts usados. El uso no reportado será calificado con nota mínima.

Objetivos de la clase

- **Preparar** variables y explorar descriptivamente la relación entre ellas
- **Estimar** modelos de regresión lineal simple con `lm()`
- **Evaluar la bondad de ajuste:** R^2 y ANOVA
- **Interpretar** coeficientes no estandarizados y estandarizados

¿Qué vimos la semana pasada en R?

- ✓ Recodificamos valores perdidos con `mutate()` y `across()`
- ✓ Calculamos correlaciones de Pearson con `cor()` y `cor.test()`
- ✓ Construimos matrices de correlación con `tab_corr()` y mapas de calor con `ggplot2`
- 💡 Hoy avanzamos hacia el análisis de regresión lineal simple.

Base de datos: Encuesta CASEN 2022

Trabajaremos con la **Encuesta de Caracterización Socioeconómica Nacional (CASEN 2022)**, aplicada entre noviembre 2022 y febrero 2023.

- **n = 202.231** personas
- Cobertura nacional, representativa a nivel regional
- Organismo responsable: Ministerio de Desarrollo Social y Familia

Las variables que usaremos hoy:

Variable	Descripción	Escala
ytrabajocor	Ingreso del trabajo (corregido)	Pesos CLP
esc	Años de escolaridad	0–29
edad	Edad	0–120
sexo	Sexo	1 Hombre / 2 Mujer

Preparación del entorno

```
1 # Ajustes previos -----
2 options(scipen = 999)
3
4 # Paquetes -----
5 library(tidyverse)
6 library(sjPlot)
7
8 # Base de datos -----
9 load("data/Casen 2022_filter.Rdata")
10
11 # Vista previa
12 data %>% glimpse()
```

Rows: 202,231

Columns: 9

\$ folio <dbl> 100090101, 100090101, 100090101, 100090201, 100090201,
100...

\$ id_persona <dbl> 1, 2, 3, 1, 2, 3, 4, 1, 2, 3, 1, 2, 1, 1, 2, 3, 4, 1, 2,
1...

\$ edad <dbl> 72, 67, 40, 56, 25, 2, 60, 84, 67, 30, 64, 62, 59, 34,
30,...

\$ sexo <dbl> 2, 1, 2, 1, 2, 1, 2, 1, 2, 1, 1, 2, 2, 1, 2, 2, 2, 1, 2,
2...

Preparación de variables

Para el análisis, trabajaremos con personas en edad laboral activa (25–65 años) que **declararon ingresos del trabajo**. Esto reduce el sesgo generado por grupos sin participación laboral típica (estudiantes, jubilados):

```
1 data_trabajo <- data %>%
2   filter(edad >= 25 & edad <= 65,
3         !is.na(ytrabajocor),
4         ytrabajocor > 0,
5         !is.na(esc))
6
7 # Etiqueta para sexo
8 data_trabajo <- data_trabajo %>%
9   mutate(sexo = factor(sexo,
10                        levels = c(1, 2),
11                        labels = c("Hombre", "Mujer")))
12
13 dim(data_trabajo)
```

```
[1] 75080    9
```


Exploración descriptiva

```
1 # Estadísticos descriptivos
2 data_trabajo %>%
3   select(Ingreso = ytrabajocor, Escolaridad = esc, Edad = edad) %>%
4   pivot_longer(everything(), names_to = "variable", values_to = "valor") %>%
5   summarise(
6     Media = mean(valor, na.rm = TRUE),
7     DE     = sd(valor, na.rm = TRUE),
8     Min    = min(valor, na.rm = TRUE),
9     Max    = max(valor, na.rm = TRUE),
10    .by = variable
11  )
```

A tibble: 3 × 5

	variable <chr>	Media <dbl>	DE <dbl>	Min <dbl>	Max <dbl>
1	Ingreso	711454.	839505.	83	50966668
2	Escolaridad	12.4	3.77	0	26
3	Edad	43.8	11.5	25	65

```
1 # Distribución por sexo
2 data_trabajo %>%
3   group_by(Sexo = sexo) %>%
4   summarise(
5     N          = n(),
6     Porcentaje = round(100 * n() / nrow(data_trabajo), 1)
7   )
```

A tibble: 2 × 3

	Sexo <fct>	N <int>	Porcentaje <dbl>
1	Hombre	41085	54.7
2	Mujer	33995	45.3

Actividad 1 para ejercicio

En una sección del script llamada `Preparación`:

1. Carga los paquetes `tidyverse` y `sjPlot`.
2. Importa la base `Base de datos Casen 2022.Rdata` con `load()` y explórala con `glimpse()`.
3. Crea el objeto `data_osig` aplicando los siguientes filtros con `filter()`:
 - Personas en edad laboral activa: `edad >= 25 & edad <= 65`
 - Con respuesta válida en `genero` (excluye `-88` y `-99`)
 - Con ingreso autónomo declarado y positivo: `!is.na(yautcor)` y `yautcor > 0`
4. Recodifica `genero` con `case_when()` en tres categorías: `"Femenino"` (valor 2), `"Masculino"` (valor 1), `"Otro"` (valores 3, 4, 5 y 6).
5. Calcula estadísticos descriptivos de `yautcor` y `tot_per_h` con `summarise()`. Incluye en comentarios (`#`): ¿cuántas personas quedaron en la muestra luego del filtro? ¿Cuál es el ingreso autónomo promedio?

Repaso: la lógica de la regresión lineal simple

El modelo de regresión lineal simple a nivel muestral estima la ecuación:

$$\hat{Y}_i = b_0 + b_1 X_i$$

Donde:

- $\hat{Y}_i$: valor predicho de la variable dependiente
- b_0 : intercepto — valor esperado de Y cuando $X = 0$
- b_1 : pendiente — cambio esperado en Y por cada unidad adicional de X

Pregunta guía de hoy:


¿En qué medida los años de escolaridad predicen el ingreso del trabajo en Chile (CASEN 2022)?

Visualización previa

Antes de estimar el modelo, exploramos la relación entre escolaridad e ingreso con un diagrama de dispersión:

```
1 ggplot(data_trabajo, aes(x = esc, y = ytrabajocor)) +  
2   geom_point(alpha = 0.05) +  
3   geom_smooth(method = "lm", color = "steelblue", se = TRUE) +  
4   scale_y_continuous(labels = scales::label_number(big.mark = ".", decimal.  
5     labs(  
6       title = "Escolaridad e ingreso del trabajo",  
7       x = "Años de escolaridad",  
8       y = "Ingreso del trabajo (CLP)",  
9       caption = "Fuente: Encuesta CASEN 2022"  
10  ) +  
11  theme_minimal()
```

Escolaridad e ingreso del trabajo



Fuente: Encuesta CASEN 2022

lm(): estimación del modelo

La función `lm()` estima modelos de regresión por mínimos cuadrados ordinarios (MCO):

```
1 # Modelo 1: escolaridad → ingreso del trabajo
2 m1 <- lm(ytrabajocor ~ esc, data = data_trabajo)
3
4 # Modelo 2: edad → ingreso del trabajo
5 m2 <- lm(ytrabajocor ~ edad, data = data_trabajo)
6
7 # Modelo 3: sexo → ingreso del trabajo (variable categórica)
8 m3 <- lm(ytrabajocor ~ sexo, data = data_trabajo)
```

`lm(VD ~ VI, data = base)` es la sintaxis básica. R trata automáticamente las variables `factor` como variables *dummy*.

Bondad de ajuste: `summary()`

Antes de leer los coeficientes, evaluamos cuánta varianza de Y logra capturar el modelo:

```
1 summary(m1)
```

Call:

```
lm(formula = ytrabajocor ~ esc, data = data_trabajo)
```

Residuals:

Min	1Q	Median	3Q	Max
-1485439	-332929	-140725	152974	50041086

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-327683.1	9789.5	-33.47	<0.00000000000000002 ***
esc	83551.0	753.3	110.92	<0.00000000000000002 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 778200 on 75078 degrees of freedom

Multiple R-squared: 0.1408, Adjusted R-squared: 0.1408

F-statistic: 1.23e+04 on 1 and 75078 DF, p-value: < 0.000000000000000022

¿Qué leemos en el output de `summary()`?

El output de `summary(lm())` entrega tres bloques clave:

1. **Residuos** — distribución de $e_i = Y_i - \hat{Y}_i$. Da una idea de cuánto se aleja el modelo de los valores observados.
2. **Coeficientes** — estimaciones de $\hat{b}_0$ y $\hat{b}_1$, con su error estándar, estadístico t y p-valor. Contrasta $H_0 : \hat{b}_1 = 0$ para cada predictor.
3. **Bondad de ajuste** — al final del output aparecen el estadístico F , su p-valor, R^2 y R^2 ajustado:
 - El estadístico F evalúa si el modelo en su conjunto capta varianza en Y más allá del azar
 - R^2 : proporción de varianza de Y capturada por el modelo (0 = nada, 1 = ajuste perfecto)
 - El R^2 ajustado penaliza por el número de predictores; es más confiable para comparar modelos

Interpretación: bondad de ajuste

A partir del output de `summary(m1)`:

- **Estadístico F y p-valor global:** el modelo es estadísticamente significativo ($F(1, 75078) = 12.300$, $p < .001$), lo que indica que la escolaridad capta varianza en el ingreso del trabajo más allá del azar.
- R^2 : la escolaridad capta el 14% de la varianza en el ingreso del trabajo. Si bien es una proporción modesta, es esperable en ciencias sociales: el ingreso es un fenómeno multideterminado que un solo predictor no puede capturar en su totalidad.
- R^2 **ajustado**: en este modelo es idéntico al R^2 (0.14), lo que es esperable en regresión simple. La diferencia entre ambos se vuelve más relevante al comparar modelos con distinto número de predictores.

Visualización de resultados: `tab_model()`

El paquete `sjPlot` permite visualizar los resultados de varios modelos en una tabla integrada. El argumento `show.std = TRUE` agrega los coeficientes estandarizados (β) directamente:

```
1 tab_model(m1, m2, m3,  
2           show.se = TRUE,  
3           show.std = TRUE,  
4           show.ci = FALSE,  
5           dv.labels = c("Modelo 1", "Modelo 2", "Modelo 3"))
```

La tabla muestra para cada predictor:

- **B:** coeficiente no estandarizado (en unidades de Y)
- **SE:** error estándar de b
- **std. Beta** (β): coeficiente estandarizado
- **p:** p-valor para $H_0 : \beta = 0$

Modelo 1						Modelo 2				
<i>Predictors</i>	<i>Estimates</i>	<i>std. Error</i>	<i>std. Beta</i>	<i>standardized std. Error</i>	<i>p</i>	<i>Estimates</i>	<i>std. Error</i>	<i>std. Beta</i>	<i>standardized std. Error</i>	<i>p</i>
(Intercept)	-327683.06	9789.55	-0.00	0.00	<0.001	819094.88	12051.13	-0.00	0.00	<0.001
Años de escolaridad (edad ≥ 15)	83551.00	753.27	0.38	0.00	<0.001					
Edad						-2460.10	266.39	-0.03	0.00	<0.001
sexo: Mujer										-
Observations	75080					75080				7
R ² / R ² adjusted	0.141 / 0.141					0.001 / 0.001				0

Interpretación de coeficientes

Para el modelo **m1** (ingreso ~ escolaridad):

- $\hat{b}_1$ (**no estandarizado**): cada año adicional de escolaridad se asocia con un aumento esperado de 83.551 pesos en el ingreso del trabajo. El coeficiente es estadísticamente significativo ($p < .001$).
- $\hat{b}_0$ (**intercepto**): el ingreso esperado para una persona con 0 años de escolaridad sería de -327.683 pesos. Este valor no tiene interpretación sustantiva, ya que un ingreso negativo no es posible y 0 años de escolaridad es un valor extremo en la muestra.
- β (**estandarizado**): por cada desviación estándar de aumento en la escolaridad, el ingreso del trabajo aumenta 0.38 desviaciones estándar. Indica un coeficiente de magnitud moderada.

Un modelo con variable categórica: sexo

Las variables categóricas se incorporan al modelo como variables *dummy*. R crea automáticamente la variable indicadora al declarar el predictor como `factor` (recomendado) o `character` en la función `lm`.

Ingreso del trabajo corregido					
<i>Predictors</i>	<i>Estimates</i>	<i>std. Error</i>	<i>std. Beta</i>	<i>standardized std. Error</i>	<i>p</i>
(Intercept)	794760.12	4117.04	0.10	0.00	<0.001
sexo [Mujer]	-183986.30	6118.42	-0.22	0.01	<0.001
Observations	75080				
R ² / R ² adjusted	0.012 / 0.012				

Interpretación

- El ingreso esperado para un hombre es 794.760 pesos
- El coeficiente de `sexo [Mujer]` indica que las mujeres tienen un ingreso esperado 183.986 pesos menor que los hombres ($p < .001$)
- El $\beta = -0.22$ indica que las mujeres tienen un ingreso 0.22 desviaciones estándar menor que los hombres

Actividad 2 para ejercicio

En una sección llamada `Modelo 1 – género`, plantea en un comentario (`#`) una pregunta de investigación con `yautcor` como VD y `genero` como VI. Luego:

1. Estima el modelo con `lm()` y evalúa la bondad de ajuste con `summary()`. Interpreta en comentarios (`#`) el estadístico F , el p-valor global y el R^2 .
2. Visualiza los coeficientes con `tab_model(show.std = TRUE)`. Interpreta en comentarios (`#`) el coeficiente b y el β .

En una sección llamada `Modelo 2 – tamaño del hogar`, plantea en un comentario (`#`) una pregunta de investigación con `yautcor` como VD y `tot_per_h` como VI. Luego:

1. Estima el modelo con `lm()` y evalúa la bondad de ajuste con `summary()`. Interpreta en comentarios (`#`) el estadístico F , el p-valor global y el R^2 .
2. Visualiza los coeficientes con `tab_model(show.std = TRUE)`. Interpreta en comentarios (`#`) el coeficiente b y el β .

? Preguntas y aclaraciones

 ¿Dudas sobre lo visto hoy?

- Tómense un momento para reflexionar y compartir preguntas sobre el contenido.
- Espacio para responder inquietudes y aclarar conceptos clave.

Resumen de la clase de hoy

- ✓ Estimamos modelos de regresión lineal simple con `lm()`
- ✓ Evaluamos la bondad de ajuste con R^2 y ANOVA
- ✓ Interpretamos coeficientes no estandarizados (b) y estandarizados (β) con `tab_model()`
- ✓ Incorporamos una variable categórica como predictor (*dummy*)



Próxima sesión

- Evaluación de supuestos del modelo de regresión lineal
- Regresión lineal múltiple en R



Sugerencias lecturas para reforzar R

- Wickham & Grolemund. R for Data Science (en español: <https://es.r4ds.hadley.nz/>)
- AnalizaR Datos Políticos
- YaRrr! The Pirate's Guide to R