

Taller 8: Regresión Logística Binomial en R

Métodos Cuantitativos II

M. Constanza Ayala

maria.ayala@uv.cl

[Agenda una reunión aquí](#)

Escuela de Sociología - Universidad de Valparaíso

10 de junio, 2026

Pasemos lista mientras descargan los materiales y dejamos todo listo ✨

 **Paso 1:** Abrimos nuestro proyecto con doble clic en el archivo `.Rproj`

- Si no tienen proyecto, creamos uno: `File > New Project > New Directory > New Project`
- Creamos carpetas: `data`, `scripts`, `figures`, `output`

 **Paso 2:** Movemos el archivo **Script Taller 8 Métodos Cuantitativos II.R** a la carpeta `scripts`

 **Paso 3:** Verificamos que la base `base_92_20112024.Rds` esté en la carpeta `data`

Todos los materiales los pueden descargar en este link: [Materiales clases](#)

Actividades prácticas

A lo largo de la clase realizaremos **dos actividades prácticas** para ejercitar cada función vista.

No tienen nota, pero recomiendo resolverlas en un script aparte para que quede como material de estudio.

- Crea un script nuevo (no uses el script de actividades de la clase) e incluye un título, tu nombre, correo y fecha. Por ejemplo:

```
1 # Actividades Taller 8 Métodos Cuantitativos II -----  
2 # M. Constanza Ayala (maria.ayala@uv.cl)  
3 # 10-06-2026
```

Objetivos de la clase

- **Estimar** modelos de regresión logística binomial con `glm()`
- **Interpretar** coeficientes en escala logit y en términos de odds ratio
- **Evaluar** la bondad de ajuste: diferencia de devianzas, AIC y pseudo- R^2 de Nagelkerke

¿Qué vimos la sesión pasada?

- ✅ Interpretamos coeficientes no estandarizados (b) y estandarizados (β) con `tab_model()`
- ✅ Interpretamos una variable categórica como *dummy* en el modelo
- ✅ Evaluamos los supuestos del modelo de regresión lineal: linealidad, independencia, homocedasticidad, normalidad de residuos y valores influyentes

💡 Hoy avanzamos hacia la **regresión logística binomial**: el modelo apropiado cuando la variable dependiente es binaria.

Preparación del entorno

```
1 # Ajustes previos -----
2 options(scipen = 999)
3
4 # Paquetes -----
5 library(tidyverse)
6 library(sjPlot)
7 library(DescTools)
8
9 # Base de datos -----
10 data <- readRDS("data/base_92_20112024.Rds")
11
12 # Vista previa
13 data %>% glimpse()
```

Rows: 1,482

Columns: 157

```
$ id_bu          <chr> "1-92", "2-92", "3-92", "4-92", "5-92", "6-92", "7-
9...
$ id_bu_encuesta <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15,
1...
$ encuesta       <dbl> 92, 92, 92, 92, 92, 92, 92, 92, 92, 92, 92, 92, 92,
...
$ encuesta_a     <dbl> 2024, 2024, 2024, 2024, 2024, 2024, 2024, 2024,
```

2024...

\$ encuesta_m

8...

\$ pond

1.249230...

<dbl> 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8,

<dbl> 0.2096586, 1.2242271, 0.4620447, 1.6158843,

Variables que usaremos

Trabajaremos con tres variables de la **Encuesta CEP N° 92** (agosto–septiembre 2024):

Variable	Pregunta (resumida)	Escala / Categorías
mtf_45_h	Una pareja del mismo sexo puede criar a un niño/a tan bien como una pareja heterosexual	1 Muy de acuerdo ... 5 Muy en desacuerdo
sexo	Sexo del encuestado/a	1 Hombre / 2 Mujer
esc_nivel_1_c	Escolaridad por nivel	Numérica (0–10)

Los valores -8 (No sabe) y -9 (No contesta) corresponden a **datos perdidos** y deben recodificarse como **NA** antes de cualquier análisis.

Preparación de variables

Recodificamos valores perdidos en la VD y en escolaridad con `across()`:

```
1 data <- data %>%
2   mutate(across(c(mtf_45_h, esc_nivel_1_c), ~ case_when(
3     . %in% c(-8, -9) ~ NA_real_,
4     TRUE ~ .
5   )))
```

Exploramos la distribución original de `mtf_45_h`:

```
1 data %>%
2   group_by(mtf_45_h) %>%
3   summarise(N = n(),
4             Porcentaje = round(100 * n() / nrow(data), 1))
```

A tibble: 6 × 3

	mtf_45_h <dbl+lbl>	N <int>	Porcentaje <dbl>
1	1 [Muy de acuerdo]	329	22.2
2	2 [De acuerdo]	512	34.5
3	3 [Ni de acuerdo ni en desacuerdo]	183	12.3
4	4 [En desacuerdo]	279	18.8
5	5 [Muy en desacuerdo]	137	9.2
6	NA	42	2.8

Binarizamos la VD: categoría 1 = “Muy de acuerdo / De acuerdo” (valores 1 y 2); categoría 0 = “Otro” (valores 3, 4 y 5):

```
1 data <- data %>%
2   mutate(mtf_45_h = case_when(
3     mtf_45_h %in% c(1, 2) ~ "Muy de acuerdo / De acuerdo",
4     mtf_45_h %in% c(3:5) ~ "Otro",
5     TRUE ~ NA_character_
6   ))
7
8 data %>%
9   group_by(mtf_45_h) %>%
10  summarise(N = n(),
11            Porcentaje = round(100 * n() / nrow(data), 1))
```

A tibble: 3 × 3

mtf_45_h	N	Porcentaje
<chr>	<int>	<dbl>
1 Muy de acuerdo / De acuerdo	841	56.7
2 Otro	599	40.4
3 <NA>	42	2.8

```
1 # Etiquetas en sexo
2 data$sexo <- factor(data$sexo,
3                     levels = c(1:2),
4                     labels = c("Hombre", "Mujer"))
5
6 # Verificamos NA en las tres variables
7 data %>%
8   summarise(across(c(mtf_45_h, sexo, esc_nivel_1_c),
9                     ~ sum(is.na(.))))
```

A tibble: 1 × 3

	mtf_45_h	sexo	esc_nivel_1_c
	<int>	<int>	<int>
1	42	0	9

```
1 # Eliminamos casos con NA en VD y escolaridad
2 data <- data %>%
3   drop_na(mtf_45_h, esc_nivel_1_c)
4
5 dim(data)
```

```
[1] 1432  157
```

Estadísticos descriptivos

```
1 # Distribución por sexo
2 data %>%
3   group_by(Sexo = sexo) %>%
4   summarise(N = n(),
5             Porcentaje = round(100 * n() / nrow(data), 1))
```

A tibble: 2 × 3

	Sexo	N	Porcentaje
	<fct>	<int>	<dbl>
1	Hombre	562	39.2
2	Mujer	870	60.8

```
1 # Distribución de la VD
2 data %>%
3   group_by(Homoparentalidad = mtf_45_h) %>%
4   summarise(N = n(),
5             Porcentaje = round(100 * n() / nrow(data), 1))
```

A tibble: 2 × 3

	Homoparentalidad	N	Porcentaje
	<chr>	<int>	<dbl>
1	Muy de acuerdo / De acuerdo	835	58.3
2	Otro	597	41.7


```
1 # Escolaridad
2 summary(data$esc_nivel_1_c)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.000	3.000	4.000	4.383	6.000	10.000

Regresión logística binaria

El modelamiento estadístico con **datos binarios** busca **estimar la probabilidad de éxito o fracaso de un evento** como una función de un conjunto de variables independientes.

- La distribución de Y es especificada por las probabilidades de éxito
 $P(Y = 1) = \pi$ o fracaso
 $P(Y = 0) = (1 - \pi)$, es decir, sigue una **distribución binomial** ($X \sim \text{Bin}(n, \pi)$).
- Hoy existen dos modelos ampliamente usados: **modelos logísticos (logit)** y **modelos probit**.



El modelo: ecuación en log-odds

La ecuación del modelo para este ejemplo es:

$$\log\left(\frac{P(\text{Acuerdo} = 1)}{1 - P(\text{Acuerdo} = 1)}\right) = \beta_0^{\wedge} + \beta_1^{\wedge} \cdot \text{Mujer} + \beta_2^{\wedge} \cdot \text{Escolar}$$

Donde:

- El lado izquierdo es el **log-odds** (logit) de que la persona esté de acuerdo con la homoparentalidad
- $\beta_0^{\wedge}$ es el intercepto: el log-odds esperado cuando todos los predictores valen cero
- $\beta_1^{\wedge}$ y $\beta_2^{\wedge}$ indican el cambio en el log-odds asociado a cada predictor
- El **signo** del coeficiente indica la dirección: $b > 0$ aumenta la probabilidad de $Y = 1$; $b < 0$ la reduce

Estimación con `glm()`

La función `glm()` con `family = "binomial"` estima el modelo logístico por máxima verosimilitud.

```
1 # Definimos la categoría de referencia de la VD
2 data$mtf_45_h <- fct_relevel(as.factor(data$mtf_45_h), "Otro")
3
4 # Modelo nulo (solo intercepto)
5 m0 <- glm(mtf_45_h ~ 1, data = data, family = "binomial")
6
7 # Modelo 1: sexo
8 m1 <- glm(mtf_45_h ~ sexo, data = data, family = "binomial")
9
10 # Modelo 2: escolaridad
11 m2 <- glm(mtf_45_h ~ esc_nivel_1_c, data = data, family = "binomial")
12
13 # Modelo 3: sexo + escolaridad
14 m3 <- glm(mtf_45_h ~ sexo + esc_nivel_1_c, data = data, family = "binomial")
```


Output de `summary()`: lectura del modelo

```
1 summary(m3)
```

Call:

```
glm(formula = mtf_45_h ~ sexo + esc_nivel_1_c, family = "binomial",  
     data = data)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.60775	0.14115	-4.306	0.00001664108779 ***
sexoMujer	0.77786	0.11204	6.943	0.000000000000384 ***
esc_nivel_1_c	0.11079	0.02451	4.519	0.00000620269277 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1945.4 on 1431 degrees of freedom
Residual deviance: 1880.2 on 1429 degrees of freedom
AIC: 1886.2

Number of Fisher Scoring iterations: 4

¿Qué leemos en el output de `summary()`?

El output entrega tres bloques clave:

- 1. Coeficientes:** estimaciones de $\hat{\beta}$ en escala de **log-odds**, con error estándar, estadístico z y p -valor. El test de Wald contrasta $H_0 : \beta_k = 0$; se rechaza si $p < .05$; $p < .01$.
- 2. Null deviance y Residual deviance:** la null deviance es el desvío del modelo sin predictores (solo intercepto); la residual deviance es el desvío del modelo con los predictores incluidos. A menor desvío residual, mejor ajuste. La diferencia entre ambos indica cuánto mejora el ajuste al incorporar los predictores.
- 3. AIC:** criterio de información de Akaike. Penaliza por el número de parámetros. A menor AIC, mejor ajuste relativo. Útil para comparar modelos estimados sobre la misma muestra.

Interpretación en escala logit

A partir del output del Modelo 3 (`mtf_45_h ~ sexo + esc_nivel_1_c`):

- **sexoMujer** ($\hat{\beta} = 0.78, p < .001$): ser mujer se asocia con un **aumento** en los log-odds de estar de acuerdo con la homoparentalidad, en comparación con los hombres, controlando por escolaridad. El coeficiente es estadísticamente significativo al 99% de confianza.
- **esc_nivel_1_c** ($\hat{\beta} = 0.11, p < .001$): cada nivel adicional de escolaridad se asocia con un **aumento** en los log-odds de acuerdo, controlando por sexo. El coeficiente es estadísticamente significativo al 99% de confianza.

Los coeficientes en escala logit indican dirección y significancia, pero su magnitud no es directamente interpretable. Para una interpretación sustantiva se utilizan los **odds ratio**.

Odds ratio

El **odds ratio** (OR) es la exponencial del coeficiente logístico:

$$OR = e^{\beta^{\wedge}}$$

Su interpretación:

- $OR > 1$: el predictor **aumenta** los odds de $Y = 1$
- $OR < 1$: el predictor **reduce** los odds de $Y = 1$
- $OR = 1$: el predictor no tiene asociación con Y

Para una variable categórica: el OR compara los odds de la categoría indicada respecto a la categoría de referencia.

Para una variable continua: el OR indica el **factor por el que se multiplican** los odds por cada unidad adicional en X .

tab_model() con odds ratio

```
1 tab_model(m1, m2, m3,  
2           show.ci = FALSE,  
3           show.se = TRUE,  
4           show.aic = TRUE,  
5           dv.labels = c("Modelo 1", "Modelo 2", "Modelo 3"))
```

	Modelo 1			Modelo 2		
<i>Predictors</i>	<i>Odds Ratios</i>	<i>std. Error</i>	<i>p</i>	<i>Odds Ratios</i>	<i>std. Error</i>	<i>p</i>
(Intercept)	0.91	0.08	0.238	0.92	0.11	0.496
sexo: Mujer	2.08	0.23	<0.001			
¿Cuál es su nivel educativo?				1.10	0.03	<0.001
Observations	1432			1432		
R ² Tjur	0.031			0.011		
AIC	1905.132			1933.167		

Interpretación del odds ratio

A partir del Modelo 3:

- **sexoMujer** (OR = 2.18, $p < .001$): los odds de que una mujer esté de acuerdo con la homoparentalidad son **2.18 veces mayores** que los de un hombre, controlando por escolaridad. Con un 99% de confianza.
- **esc_nivel_1_c** (OR = 1.12, $p < .001$): por cada año adicional de escolaridad, los odds de acuerdo se **multiplican por 1.12**, controlando por sexo. Con un 99% de confianza.

Cálculo manual del OR

También es posible obtener los odds ratio directamente desde los coeficientes:

```
1 # Odds ratio del modelo 3
2 exp(coef(m3))
```

(Intercept)	sexoMujer	esc_nivel_1_c
0.5445759	2.1768004	1.1171600

```
1 # Interpretación de sexoMujer: aumento porcentual en los odds
2 (exp(coef(m3)["sexoMujer"]) - 1) * 100
```

```
sexoMujer
117.68
```

El aumento porcentual en los odds se calcula como $(OR - 1) \times 100$. En este caso, los odds de acuerdo son aproximadamente un **118% mayores** entre las mujeres que entre los hombres.

Actividad práctica 1

En el script de actividades, en una sección llamada `Modelo logístico`:

1. Recodifica `religion_14` de la siguiente forma en una sección llamada `Preparación VD`:
 - Excluye los valores no válidos (-8 y -9) como `NA`
 - Categoría `"Sí"`: valor 3 (el aborto debe ser una opción para las mujeres, en cualquier caso)
 - Categoría `"No"`: valores 1 y 2 (siempre prohibido / solo en casos especiales)
 - Define `"No"` como categoría de referencia con `fct_relevel()`
2. Estima tres modelos con `glm(family = "binomial")` en una sección llamada `Modelos`:
 - `m0_aborto: religion_14 ~ 1`
 - `m1_aborto: religion_14 ~ sexo`
 - `m2_aborto: religion_14 ~ sexo + esc_nivel_1_c`
3. Visualiza los resultados con `tab_model(show.exp = TRUE, show.ci = TRUE)`.
4. Incluye en comentarios (`#`) la interpretación del OR de cada predictor en `m2_aborto`: dirección, magnitud y significancia estadística.

Bondad de ajuste

A diferencia de la regresión lineal, el modelo logístico no cuenta con un R^2 en sentido estricto. Utilizamos tres indicadores complementarios:

- 1. Diferencia de devianzas** — chi-cuadrado del modelo: diferencia entre la devianza nula y la devianza residual. Contrasta si los predictores mejoran el ajuste respecto al modelo sin predictores.
- 2. AIC** — permite comparar modelos estimados sobre la misma muestra. Penaliza la complejidad del modelo; se prefiere el modelo con menor AIC.
- 3. Pseudo- R^2 de Nagelkerke** — análogo al R^2 de MCO; varía entre 0 y 1. Indica la proporción de varianza en Y capturada por el modelo, aunque su interpretación es aproximada.

Cálculo de los indicadores

```
1 # 1. Diferencia de devianzas (chi-cuadrado del modelo)
2 # H0: el modelo con predictores no mejora el ajuste respecto al modelo nulo
3 anova(m0, m3, test = "Chisq")
```

Analysis of Deviance Table

Model 1: mtf_45_h ~ 1

Model 2: mtf_45_h ~ sexo + esc_nivel_1_c

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	1431	1945.4			
2	1429	1880.2	2	65.23	0.00000000000000006847 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
1 # 2. AIC
2 AIC(m0, m1, m2, m3)
```

	df	AIC
m0	1	1947.434
m1	2	1905.132
m2	2	1933.167
m3	3	1886.204

```
1 # 3. Pseudo-R² de Nagelkerke (DescTools)
2 PseudoR2(m3, which = "Nagelkerke")
```

Nagelkerke
0.05993505

Interpretación: bondad de ajuste

Para el Modelo 3 (`mtf_45_h ~ sexo + esc_nivel_1_c`):

- **Chi-cuadrado del modelo:** $\chi^2(2) = 65.23$, $p < .001$. Se rechaza H_0 : el modelo con sexo y escolaridad mejora significativamente el ajuste respecto al modelo nulo. Los predictores capturan varianza en la VD más allá del azar.
- **AIC:** el Modelo 3 presenta el menor AIC entre los cuatro modelos estimados (AIC = 1886.20), lo que indica que es el modelo con mejor ajuste relativo.
- **Pseudo- R^2** de Nagelkerke: 0.06. El valor indica un ajuste modesto, lo que es esperable: las actitudes son fenómenos multideterminados que un modelo con dos predictores no puede capturar en su totalidad.

Actividad práctica 2

En el script de actividades, en una sección llamada **Bondad de ajuste**:

1. Calcula la **diferencia de devianzas** entre el modelo `m0_aborto` y `m2_aborto`. ¿Se rechaza H_0 ? ¿Qué implica eso?
2. Compara el **AIC** de `m0_aborto`, `m1_aborto` y `m2_aborto` con `AIC()`. ¿Cuál presenta mejor ajuste?
3. Calcula el **pseudo- R^2** de Nagelkerke de `m2_aborto` con `DescTools::PseudoR2()`. ¿Qué nos indica?
4. Incluye en comentarios (`#`) una conclusión breve integrando los tres indicadores: ¿cuál es el modelo con el mejor ajuste?

? Preguntas y aclaraciones

 ¿Dudas sobre lo visto hoy?

- Tómense un momento para reflexionar y compartir preguntas sobre el contenido.
- Espacio para responder inquietudes y aclarar conceptos clave.

Resumen de la clase de hoy

- ✓ Estimamos modelos de regresión logística binomial con `glm(family = "binomial")`
- ✓ Interpretamos coeficientes en escala logit:
- ✓ Calculamos e interpretamos odds ratio
- ✓ Evaluamos la bondad de ajuste: diferencia de devianzas, AIC y pseudo- R^2 de Nagelkerke



Próxima sesión

- Ejercicio recuperativo



Sugerencias lecturas

- Wickham & Grolemund. R for Data Science (en español: <https://es.r4ds.hadley.nz/>)
- AnalizaR Datos Políticos
- YaRrr! The Pirate's Guide to R