

Taller 9: R. Logística Binomial II en R

Métodos Cuantitativos II

M. Constanza Ayala

maria.ayala@uv.cl

[Agenda una reunión aquí](#)

Escuela de Sociología - Universidad de Valparaíso

17 de junio, 2026

Pasemos lista mientras descargan los materiales y dejamos todo listo ✨

 **Paso 1:** Abrimos nuestro proyecto con doble clic en el archivo `.Rproj`

- Si no tienen proyecto, creamos uno: `File > New Project > New Directory > New Project`
- Creamos carpetas: `data`, `scripts`, `figures`, `output`

 **Paso 2:** Movemos el archivo **Script Taller 9 Métodos Cuantitativos II.R** a la carpeta `scripts`

 **Paso 3:** Verificamos que la base `base_92_20112024.Rds` esté en la carpeta `data`

Todos los materiales los pueden descargar en este link: [Materiales clases](#)

Objetivos de la clase

- **Estimar** modelos de regresión logística binomial con `glm()`
- **Interpretar** coeficientes en escala logit y en términos de odds ratio

Evaluación recuperativa

Hoy tenemos la **evaluación individual recuperativa** en R. Debes entregar lo siguiente:

- Proyecto de R ([.Rproj](#)).
- El script ([.R](#)) que contiene todos los ejercicios individuales solicitados en este taller. Debes crear un script nuevo, no utilices el script de actividades entregado en la clase.
 - En ese script, incluye un título, tu nombre, correo y fecha. Por ejemplo:

```
1 # Script Ejercicio recuperativo Métodos Cuantitativos II -----  
2 # M. Constanza Ayala (maria.ayala@uv.cl)  
3 # 16-05-2026
```

Plazo de entrega: hoy hasta las 17:45 hrs. al correo maria.ayala@uv.cl. Debe esperar que la profesora confirme la recepción de su correo.

En caso de utilizar IA, debe reportarlo en un archivo Word, indicando la herramienta y los prompts usados. El uso no reportado será calificado con nota mínima.

Preparación del entorno

```
1 # Ajustes previos -----
2 options(scipen = 999)
3
4 # Paquetes -----
5 library(tidyverse)
6 library(sjPlot)
7 library(DescTools)
8
9 # Base de datos -----
10 data <- readRDS("data/base_92_20112024.Rds")
11
12 # Vista previa
13 data %>% glimpse()
```

Rows: 1,482

Columns: 157

```
$ id_bu          <chr> "1-92", "2-92", "3-92", "4-92", "5-92", "6-92", "7-
9...
$ id_bu_encuesta <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15,
1...
$ encuesta       <dbl> 92, 92, 92, 92, 92, 92, 92, 92, 92, 92, 92, 92, 92,
...
$ encuesta_a     <dbl> 2024, 2024, 2024, 2024, 2024, 2024, 2024, 2024,
```

2024...

\$ encuesta_m

8...

\$ pond

1.249230...

<dbl> 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8, 8,

<dbl> 0.2096586, 1.2242271, 0.4620447, 1.6158843,

Variables que usaremos

Trabajaremos con tres variables de la **Encuesta CEP N° 92** (agosto–septiembre 2024):

Variable	Pregunta (resumida)	Escala / Categorías
<code>mtf_45_h</code>	Una pareja del mismo sexo puede criar a un niño/a tan bien como una pareja heterosexual	1 Muy de acuerdo ... 5 Muy en desacuerdo
<code>sexo</code>	Sexo del encuestado/a	1 Hombre / 2 Mujer
<code>esc_nivel_1_c</code>	Escolaridad por nivel	Numérica (0–10)

Los valores -8 (No sabe) y -9 (No contesta) corresponden a **datos perdidos** y deben recodificarse como **NA** antes de cualquier análisis.

Preparación de variables

Recodificamos valores perdidos en la VD y en escolaridad con `across()`:

```
1 data <- data %>%
2   mutate(across(c(mtf_45_h, esc_nivel_1_c), ~ case_when(
3     . %in% c(-8, -9) ~ NA_real_,
4     TRUE ~ .
5   )))
```

Exploramos la distribución original de `mtf_45_h`:

```
1 data %>%
2   group_by(mtf_45_h) %>%
3   summarise(N = n(),
4             Porcentaje = round(100 * n() / nrow(data), 1))
```

A tibble: 6 × 3

	mtf_45_h <dbl+lbl>	N <int>	Porcentaje <dbl>
1	1 [Muy de acuerdo]	329	22.2
2	2 [De acuerdo]	512	34.5
3	3 [Ni de acuerdo ni en desacuerdo]	183	12.3
4	4 [En desacuerdo]	279	18.8
5	5 [Muy en desacuerdo]	137	9.2
6	NA	42	2.8

Binarizamos la VD: categoría 1 = “Muy de acuerdo / De acuerdo” (valores 1 y 2); categoría 0 = “Otro” (valores 3, 4 y 5):

```
1 data <- data %>%
2   mutate(mtf_45_h = case_when(
3     mtf_45_h %in% c(1, 2) ~ "Muy de acuerdo / De acuerdo",
4     mtf_45_h %in% c(3:5) ~ "Otro",
5     TRUE ~ NA_character_
6   ))
7
8 data %>%
9   group_by(mtf_45_h) %>%
10  summarise(N = n(),
11            Porcentaje = round(100 * n() / nrow(data), 1))
```

A tibble: 3 × 3

mtf_45_h	N	Porcentaje
<chr>	<int>	<dbl>
1 Muy de acuerdo / De acuerdo	841	56.7
2 Otro	599	40.4
3 <NA>	42	2.8

```
1 # Etiquetas en sexo
2 data$sexo <- factor(data$sexo,
3                     levels = c(1:2),
4                     labels = c("Hombre", "Mujer"))
5
6 # Verificamos NA en las tres variables
7 data %>%
8   summarise(across(c(mtf_45_h, sexo, esc_nivel_1_c),
9                     ~ sum(is.na(.))))
```

A tibble: 1 × 3

	mtf_45_h	sexo	esc_nivel_1_c
	<int>	<int>	<int>
1	42	0	9

```
1 # Eliminamos casos con NA en VD y escolaridad
2 data <- data %>%
3   drop_na(mtf_45_h, esc_nivel_1_c)
4
5 dim(data)
```

```
[1] 1432 157
```

Estadísticos descriptivos

```
1 # Distribución por sexo
2 data %>%
3   group_by(Sexo = sexo) %>%
4   summarise(N = n(),
5             Porcentaje = round(100 * n() / nrow(data), 1))
```

A tibble: 2 × 3

	Sexo	N	Porcentaje
	<fct>	<int>	<dbl>
1	Hombre	562	39.2
2	Mujer	870	60.8

```
1 # Distribución de la VD
2 data %>%
3   group_by(Homoparentalidad = mtf_45_h) %>%
4   summarise(N = n(),
5             Porcentaje = round(100 * n() / nrow(data), 1))
```

A tibble: 2 × 3

	Homoparentalidad	N	Porcentaje
	<chr>	<int>	<dbl>
1	Muy de acuerdo / De acuerdo	835	58.3
2	Otro	597	41.7

```
1 # Escolaridad
2 summary(data$esc_nivel_1_c)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.000	3.000	4.000	4.383	6.000	10.000

Regresión logística binaria


El modelamiento estadístico con **datos binarios** busca **estimar la probabilidad de éxito o fracaso de un evento** como una función de un conjunto de variables independientes.

- La distribución de Y es especificada por las probabilidades de éxito

$$P(Y = 1) = \pi \text{ o fracaso}$$

$P(Y = 0) = (1 - \pi)$, es decir, sigue una **distribución binomial** ($X \sim \text{Bin}(n, \pi)$).

- Hoy existen dos modelos ampliamente usados: **modelos logísticos (logit)** y **modelos probit**.



El modelo: ecuación en log-odds

La ecuación del modelo para este ejemplo es:

$$\log\left(\frac{P(\text{Acuerdo} = 1)}{1 - P(\text{Acuerdo} = 1)}\right) = \beta_0^{\wedge} + \beta_1^{\wedge} \cdot \text{Mujer} + \beta_2^{\wedge} \cdot \text{Escolar}$$

Donde:

- El lado izquierdo es el **log-odds** (logit) de que la persona esté de acuerdo con la homoparentalidad
- $\beta_0^{\wedge}$ es el intercepto: el log-odds esperado cuando todos los predictores valen cero
- $\beta_1^{\wedge}$ y $\beta_2^{\wedge}$ indican el cambio en el log-odds asociado a cada predictor
- El **signo** del coeficiente indica la dirección: $b > 0$ aumenta la probabilidad de $Y = 1$; $b < 0$ la reduce

Estimación con `glm()`

La función `glm()` con `family = "binomial"` estima el modelo logístico por máxima verosimilitud.

```
1 # Definimos la categoría de referencia de la VD
2 data$mtf_45_h <- fct_relevel(as.factor(data$mtf_45_h), "Otro")
3
4 # Modelo nulo (solo intercepto)
5 m0 <- glm(mtf_45_h ~ 1, data = data, family = "binomial")
6
7 # Modelo 1: sexo
8 m1 <- glm(mtf_45_h ~ sexo, data = data, family = "binomial")
9
10 # Modelo 2: escolaridad
11 m2 <- glm(mtf_45_h ~ esc_nivel_1_c, data = data, family = "binomial")
12
13 # Modelo 3: sexo + escolaridad
14 m3 <- glm(mtf_45_h ~ sexo + esc_nivel_1_c, data = data, family = "binomial")
```

Output de `summary()`: lectura del modelo

```
1 summary(m3)
```

Call:

```
glm(formula = mtf_45_h ~ sexo + esc_nivel_1_c, family = "binomial",  
     data = data)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.60775	0.14115	-4.306	0.00001664108779 ***
sexoMujer	0.77786	0.11204	6.943	0.000000000000384 ***
esc_nivel_1_c	0.11079	0.02451	4.519	0.00000620269277 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1945.4 on 1431 degrees of freedom
Residual deviance: 1880.2 on 1429 degrees of freedom
AIC: 1886.2

Number of Fisher Scoring iterations: 4

¿Qué leemos en el output de `summary()`?

El output entrega tres bloques clave:

- 1. Coeficientes:** estimaciones de $\hat{\beta}$ en escala de **log-odds**, con error estándar, estadístico z y p -valor. El test de Wald contrasta $H_0 : \beta_k = 0$; se rechaza si $p < .05$; $p < .01$.
- 2. Null deviance y Residual deviance:** la null deviance es el desvío del modelo sin predictores (solo intercepto); la residual deviance es el desvío del modelo con los predictores incluidos. A menor desvío residual, mejor ajuste. La diferencia entre ambos indica cuánto mejora el ajuste al incorporar los predictores.
- 3. AIC:** criterio de información de Akaike. Penaliza por el número de parámetros. A menor AIC, mejor ajuste relativo. Útil para comparar modelos estimados sobre la misma muestra.

Interpretación en escala logit

A partir del output del Modelo 3 (`mtf_45_h ~ sexo + esc_nivel_1_c`):

- **sexoMujer** ($\hat{\beta} = 0.78, p < .001$): ser mujer se asocia con un **aumento** en los log-odds de estar de acuerdo con la homoparentalidad, en comparación con los hombres, controlando por escolaridad. El coeficiente es estadísticamente significativo al 99% de confianza.
- **esc_nivel_1_c** ($\hat{\beta} = 0.11, p < .001$): cada nivel adicional de escolaridad se asocia con un **aumento** en los log-odds de acuerdo, controlando por sexo. El coeficiente es estadísticamente significativo al 99% de confianza.

Los coeficientes en escala logit indican dirección y significancia, pero su magnitud no es directamente interpretable. Para una interpretación sustantiva se utilizan los **odds ratio**.

Odds ratio

El **odds ratio** (OR) es la exponencial del coeficiente logístico:

$$OR = e^{\beta^{\wedge}}$$

Su interpretación:

- $OR > 1$: el predictor **aumenta** los odds de $Y = 1$
- $OR < 1$: el predictor **reduce** los odds de $Y = 1$
- $OR = 1$: el predictor no tiene asociación con Y

Para una variable categórica: el OR compara los odds de la categoría indicada respecto a la categoría de referencia.

Para una variable continua: el OR indica el **factor por el que se multiplican** los odds por cada unidad adicional en X .

tab_model() con odds ratio

```
1 tab_model(m1, m2, m3,  
2           show.ci = FALSE,  
3           show.se = TRUE,  
4           show.aic = TRUE,  
5           dv.labels = c("Modelo 1", "Modelo 2", "Modelo 3"))
```

	Modelo 1			Modelo 2		
<i>Predictors</i>	<i>Odds Ratios</i>	<i>std. Error</i>	<i>p</i>	<i>Odds Ratios</i>	<i>std. Error</i>	<i>p</i>
(Intercept)	0.91	0.08	0.238	0.92	0.11	0.496
sexo: Mujer	2.08	0.23	<0.001			
¿Cuál es su nivel educativo?				1.10	0.03	<0.001
Observations	1432			1432		
R ² Tjur	0.031			0.011		
AIC	1905.132			1933.167		

Interpretación del odds ratio

A partir del Modelo 3:

- **sexoMujer** (OR = 2.18, $p < .001$): los odds de que una mujer esté de acuerdo con la homoparentalidad son **2.18 veces mayores** que los de un hombre, controlando por escolaridad. Con un 99% de confianza.
- **esc_nivel_1_c** (OR = 1.12, $p < .001$): por cada año adicional de escolaridad, los odds de acuerdo se **multiplican por 1.12**, controlando por sexo. Con un 99% de confianza.

Cálculo manual del OR

También es posible obtener los odds ratio directamente desde los coeficientes:

```
1 # Odds ratio del modelo 3
2 exp(coef(m3))
```

(Intercept)	sexoMujer	esc_nivel_1_c
0.5445759	2.1768004	1.1171600

```
1 # Interpretación de sexoMujer: aumento porcentual en los odds
2 (exp(coef(m3)["sexoMujer"]) - 1) * 100
```

```
sexoMujer
117.68
```

El aumento porcentual en los odds se calcula como $(OR - 1) \times 100$. En este caso, los odds de acuerdo son aproximadamente un **118% mayores** entre las mujeres que entre los hombres.

Actividad práctica

Van a trabajar con la variable `percepcion_3`: *¿Ud. piensa que en los próximos 12 meses la situación económica del país mejorará, no cambiará o empeorará?*

1. En una sección llamada **Preparación**: Carga los paquetes `tidyverse`, `haven`, `sjPlot` y `DescTools`, y la base `base_92_20112024.Rds`.
2. Recodifica `percepcion_3` con `mutate` y `case_when`: (1) Excluye los valores no válidos (-8 y -9) como `NA`. (2) Categoría "Empeorará": valor 3. (3) Categoría "Mejorará o no cambiará": valores 1 y 2. Define "Mejorará o no cambiará" como categoría de referencia con `fct_relevel()`.
3. Asigna etiquetas con `factor()` a la variable `sexo`: 1 = "Hombre", 2 = "Mujer".
4. Elimina los NA de las variables `percepcion_3`, `sexo` y `esc_nivel_1_c` con `drop_na()`.
5. En una sección llamada **Modelos de regresión logística**: Estima dos modelos con `glm(family = "binomial")`: (1) `m1: percepcion_3 ~ sexo`. (2) `m2: percepcion_3 ~ sexo + esc_nivel_1_c`.
6. Visualiza los resultados con `tab_model(show.exp = TRUE, show.ci = FALSE, show.se = TRUE)` e incluye en comentarios (`#`) la interpretación del OR de cada predictor en `m2`: dirección, magnitud y significancia estadística.

? Preguntas y aclaraciones

 ¿Dudas sobre lo visto hoy?

- Tómense un momento para reflexionar y compartir preguntas sobre el contenido.
- Espacio para responder inquietudes y aclarar conceptos clave.

Resumen de la clase de hoy

- ✓ Estimamos modelos de regresión logística binomial con `glm(family = "binomial")`
- ✓ Interpretamos coeficientes en escala logit
- ✓ Calculamos e interpretamos odds ratio



Sugerencias lecturas

- Wickham & Grolemund. R for Data Science (en español: <https://es.r4ds.hadley.nz/>)
- AnalizaR Datos Políticos
- YaRrr! The Pirate's Guide to R